

DATA PROJECT: PROYECTO FINAL

Análisis de Telemetría, Estrategia de Carrera y Rendimiento Histórico en la



Herramientas ETL/EDA: Python (Pandas, VS Code)

Dashboarding: Power BI

Laura Mayorgas del Castillo

Septiembre 2026

ÍNDICE

1. INTRODUCCIÓN Y CONTEXTO GENERAL.....	2
2. ORIGEN Y DESCARGA DE LAS FUENTES DE DATOS.....	2
3. DESCRIPCIÓN DETALLADA DE LOS FICHEROS EN BRUTO.....	2
4. UNIÓN Y LIMPIEZA DE DATOS.....	3
4.1 Estrategia de Unificación de Fuentes (Merge Relacional).....	3
4.2 Limpieza y creación de variables.....	4
4.3 Exportación del Dataset Procesado.....	4
5. ANÁLISIS EXPLORATORIO DE DATOS.....	4
5.1 Resumen Estadístico Descriptivo.....	4
5.2 Bloques de Análisis de Interés y Hallazgos Clave.....	5
<i>Estudio 1: Capacidad de remontada por piloto.....</i>	<i>5</i>
<i>Estudio 2: Fiabilidad mecánica real y tasa de abandonos (DNFs) por escudería.....</i>	<i>6</i>
<i>Estudio 3: Percentiles en paradas en boxes (Pit Stops).....</i>	<i>6</i>
<i>Estudio 4: Evolución de edad de la parrilla por décadas.....</i>	<i>6</i>
<i>Estudio 5: Impacto de la vuelta rápida en el resultado.....</i>	<i>7</i>
<i>Estudio 6: Dificultad de remontada y sensibilidad a la trazada.....</i>	<i>7</i>
6. MODELADO EN POWER BI.....	8
6.1 Carga y limpieza previa en Power Query.....	8
6.2 Arquitectura del Modelo Relacional.....	8
6.3 Cálculo de Medidas.....	9
6.4 Estructura del Dashboard.....	9
<i>Página 1: Dashboard : Rendimiento histórico (1982–2012).....</i>	<i>10</i>
<i>Página 2: Dashboard Técnico: Telemetría y comparativa de ritmo.....</i>	<i>13</i>
7. CONCLUSIÓN.....	14

1. INTRODUCCIÓN Y CONTEXTO GENERAL

La Fórmula 1 (F1) es mundialmente conocida por ser la **cúspide del automovilismo** deportivo y es, por definición, una de las disciplinas más intensivas en el uso de datos e ingeniería analítica en el mundo.

Un monoplace moderno de F1 está equipado con cientos de sensores de telemetría que generan **más de 1.1 mil millones de puntos de datos durante un solo fin de semana de carrera**. Sin embargo, la ventaja competitiva no reside únicamente en la adquisición de los datos en bruto, sino en la capacidad analítica de transformar esta ingente cantidad de métricas operativas en decisiones estratégicas óptimas en tiempo real.

El presente proyecto aborda el análisis del ecosistema de la Fórmula 1 combinando dos dimensiones fundamentales: el rendimiento histórico incluyendo variables como: resultados, escuderías, pilotos y circuitos desde 1950 y el análisis táctico de los tiempos vuelta a vuelta y paradas en boxes o pit stops. Gracias a todo este conjunto y volumen de datos, el proyecto pretende atacar algunas de las principales incógnitas que los apasionados del mundo del motor se hacen, como: la eficiencia en la parada de boxes y la correlación entre la posición en la parrilla de salida (grid) y la posición final de carrera, y muchos más que iremos viendo a lo largo del trabajo.

2. ORIGEN Y DESCARGA DE LAS FUENTES DE DATOS

Los conjuntos de datos utilizados en este proyecto provienen de fuentes públicas. Los ficheros han sido obtenidos desde la plataforma [Kaggle](#), basados en la API histórica de [Ergast F1 Motor Racing Data](#) (mantenida y actualizada para cubrir el período histórico completo 1950–2026).

3. DESCRIPCIÓN DETALLADA DE LOS FICHEROS EN BRUTO

A continuación se detalla la estructura, dimensiones y contenido técnico de cada uno de los 7 ficheros `.csv`.

Nota: Todos estos pueden ser descargados e inspeccionados en la carpeta rawdata/ del proyecto.

- **races.csv:** Dataset más importante, donde se guarda toda la información relativa a las carreras por año/temporada incluyendo información como: nombre del Gran Premio, fecha, horario, etc.
- **drivers.csv:** Conjunto de datos históricos de pilotos incluyendo sus nombres e información personal como nacionalidad o fecha de nacimiento.
- **constructors.csv:** Catálogo de todas las escuderías (Ferrari, McLaren, Redbull, ...) incluyendo el nombre comercial y la nacionalidad del equipo.
- **circuits.csv:** Información geográfica de los circuitos: nombre oficial, país y datos de geolocalización más exhaustivos.
- **lap_times:** Telemetría de tiempo por vuelta de cada piloto en cada Gran Premio. Contiene el tiempo exacto en milisegundos y posición en la carrera vuelta a vuelta. Fuente principal de gran volumen de datos del proyecto.
- **pit_stops.csv:** Detalle de cada parada en boxes, vuelta en la que se realizó, y más importante duración de la misma.
- **results.csv:** Resultados finales de cada carrera: posición de salida y final, resultado en puntos obtenidos para el mundial, accidentes, vuelta rápida y mucha más información de interés.

4. UNIÓN Y LIMPIEZA DE DATOS

Una vez explicados todos los dataframes iniciales brutos que componen el grosso de este trabajo, se procede a la creación de un único archivo .csv unificado. Esta consolidación previa nos permite centralizar el flujo de limpieza y trabajar sobre un modelo analítico único y coherente. ([1-LimpiezaDatos.ipynb](#).)

4.1 Estrategia de Unificación de Fuentes (Merge Relacional)

Para integrar las 7 fuentes independientes sin perder la granularidad de la telemetría, se aplicó un proceso de unión relacional en tres fases:

- **Unión de metadatos y de resultados:** Se combinó la tabla results con races, drivers, constructors y circuits usando sus correspondientes claves primarias (raceId, driverId, constructorId, circuitId).
- **Integración de Telemetría:** Se enlazó la tabla de metadatos con lap_times (+870.000 registros) utilizando la clave compuesta [raceId, driverId].
- **Anexo Operativo de Boxes:** Se realizó un LEFT JOIN con la tabla pit_stops sobre [raceId, driverId, lap], garantizando que las vueltas estándar no se descarten y manteniendo los datos de paradas solo cuando la maniobra ocurrió.

4.2 Limpieza y creación de variables

Sobre el dataframe consolidado se ejecutó el tratamiento de calidad de datos y la creación de nuevas variables de negocio:

- **Tratamiento de Nulos:** Se identificó que la secuencia \N del origen representaba nulos (NaN). Se transformaron las salidas desde el pit lane en grid asignándoles la peor posición de la parrilla de esa carrera, y se rellenaron los nulos aislados de duración de paradas con la mediana.
- **Creación de Identificadores Únicos:** Ante la falta de dorsales fijos y códigos de 3 letras antes de 2014, se creó la columna `driver_full_name` (Nombre + Apellido) como identificador para cada conductor.
- **Métricas Continuas:** Se convirtió el tiempo por vuelta a segundos (`lap_seconds`) y la duración de las paradas a segundos (`pit_seconds`).
- **Nuevas variables:** Se calculó la edad exacta del piloto el día de la carrera (`driver_age`), la ganancia neta de posiciones (`positions_gained = grid - positionOrder`) y la marca de vuelta con parada (`is_pit_stop`).

4.3 Exportación del Dataset Procesado

El archivo consolidado resultante se exportó a la ruta del proyecto:

- **Ruta local:** `f1_data.csv` (no se encuentra en ninguna carpeta)
- **Dimensión Final:** 879.870 filas y 52 columnas (cumpliendo y superando ampliamente el requisito mínimo de 50.000 filas x 20 columnas).

5. ANÁLISIS EXPLORATORIO DE DATOS

Para evaluar las dinámicas de rendimiento, estrategia y fiabilidad, se desarrolló un Análisis Exploratorio de Datos (EDA) utilizando las librerías **Pandas** y **NumPy**.

Toda la ejecución paso a paso, funciones, trazabilidad de código y conclusiones se encuentran documentadas en el notebook oficial del proyecto:

[2-AnalisisEDA.ipynb](#).

5.1 Resumen Estadístico Descriptivo

El conjunto de datos procesado (`f1_data.csv`) consta de **278.678 registros** distribuidos en 52 columnas. Para comenzar con el proyecto y de esta manera empezar a familiarizarse con el conjunto de datos y tener una primera imagen global del mismo se realizó el cálculo de los estadísticos de tendencia central y dispersión sobre las variables cuantitativas clave reflejan la amplitud del dataset:

- **Tiempos de Vuelta (*lap_seconds*):** Presentan una media global de 95,64 segundos y una mediana de 90,71 segundos, con una desviación estándar de 78,12 segundos. Los valores máximos (hasta 7.507,55 s) corresponden a periodos prolongados bajo la condición y salida de un *safety-car* (coche de seguridad) o neutralizaciones por bandera roja.
- **Demografía de Pilotos (*driver_age*):** La edad media de participación en carrera se sitúa en **29,89 años** (mediana de 30,00 años), abarcando un rango de entre 20 y 43 años.
- **Posición de Salida y Llegada (*grid* vs *positionOrder*):** La posición media en la parrilla de salida es de 12,63, mientras que la posición media de llegada oficial es de 9,99. Tiene sentido y coherencia ya que hay 20 pilotos en la parrilla disputando un Gran premio, por lo que la mediana es como debe aproximadamente 10.
- **Métrica de Remontadas (*positions_gained* = *grid* - *positionOrder*):** La ganancia media de posiciones es de **+2,64 puestos** por piloto, con un rango de variación bastante extrema de entre -25,00 y +22,00 posiciones. Esto confirma la incertidumbre y variabilidad de los puestos en este deporte de alto rendimiento y confirma que cada carrera cuenta para ganar el mundial y todos pueden verse afectados por problemas externos al comportamiento del monoplaza.
- **Conversión de Pole Position:** Sobre 244 carreras únicas analizadas con registro completo de parrilla, en **97 ocasiones (39,75%)** el piloto que partió desde la *Pole Position* (*grid* = 1) se proclamó ganador del Gran Premio.

5.2 Bloques de Análisis de Interés y Hallazgos Clave

A través de consultas específicas en Python, se ejecutaron 6 estudios más profundos (cuyas funciones detalladas y outputs exactos se pueden consultar en el Jupyter Notebook [2-AnalisisEDA.ipynb](#)):

Estudio 1: Capacidad de remontada por piloto

- **Metodología:** Filtrado de pilotos con un mínimo de 30 Grandes Premios disputados y cálculo de la media, máximo y desviación estándar de posiciones ganadas en las mismas.
- **Conclusión principal:** Pilotos que partieron habitualmente de la zona media/baja de la parrilla (por encima de la décima posición) como Jonathan Palmer (media +6,59 posiciones) o Christian Fittipaldi (+6,35) registran las mayores remontadas medias. La elevada varianza de aproximadamente 7,42 confirma que la recuperación de puestos depende

fuertemente de incidentes en la primera vuelta y dispersión estratégica.

Estudio 2: Fiabilidad mecánica real y tasa de abandonos (DNFs) por escudería

- **Metodología:** Se resolvió el sesgo técnico identificando en la tabla `status.csv` donde `statusId == 1` representa únicamente al ganador sin doblar. Se creó una lista condicional con los valores `[1, 11, 12, ..., 19]` para marcar como finalizados a todos los coches clasificados (incluyendo doblados) y contabilizar únicamente los abandonos reales por avería o accidente.
- **Conclusión principal:** : Las escuderías de la era moderna encabezan la fiabilidad histórica: **Mercedes** registra un **11,88% de abandonos**, seguida por **Alpine (14,29%)** y **Red Bull (17,33%)**. Escuderías históricas de larga trayectoria como **Ferrari (30,11%)** o **McLaren (30,33%)** presentan tasas superiores debido a la menor fiabilidad mecánica de las décadas de 1950 a 1990.

Estudio 3: Percentiles en paradas en boxes (Pit Stops)

- **Metodología:** Aplicación de funciones de percentiles de NumPy (`np.percentile`) sobre la muestra de paradas registradas.
- **Conclusión principal:** Muestra una distribución asimétrica positiva. La media matemática (**30,14 s**) se halla inflada por *outliers* (paradas accidentadas o reparaciones). Por ello, la **mediana = 25,50** representa el umbral real de una parada estándar. El rango intercuartílico $P25 = 22,23$ para paradas limpias vs $P75 = 31,43$ para paradas con tráfico en boxes deja una ventana táctica de 9,20 segundos para ejecutar un *undercut* con éxito.

Estudio 4: Evolución de edad de la parrilla por décadas

- **Metodología:** Agregación por época mediante división entera del año (`year // 10`) * 10 sobre participaciones únicas por piloto y Gran Premio.
- **Conclusión principal:** : Confirmación de la tendencia al rejuvenecimiento de los pilotos de la F1. Como dato interesante, esto puede verse también a día de hoy donde Kimi Antonelli, ganador del último gran premio disputado hasta la fecha en Monza, Italia, tiene tan solo 20 años. Gracias al estudio podemos ver que la edad media descendió de los **30,12 años en la década de 1980** a **29,76 años en los 90** y **28,46 años en la década de**

2010, manteniéndose la edad mínima de debut en los 20-21 años por la profesionalización en academias de karting.

Estudio 5: Impacto de la vuelta rápida en el resultado

- **Metodología:** Conversión a valor numérico de **rank** y filtrado del piloto con la vuelta más rápida del Gran Premio (**rank_num == 1**).
- **Conclusión principal:** El piloto que firma la vuelta rápida obtiene un promedio de **17,83 puntos** y una posición media de llegada de **2,83**. Además, en el **43,48% de las ocasiones**, marcar la vuelta rápida coincide con alzarse con la victoria final del Gran Premio.

Estudio 6: Dificultad de remontada y sensibilidad a la trazada

- **Metodología:** Agregación del promedio de **positions_gained** por trazado, filtrando aquellos con un mínimo de 20 carreras disputadas (**query('carreras_disputadas >= 20')**) para evitar sesgos de muestra.
- **Conclusión principal:** : Trazados urbanos o de baja anchura como **Zandvoort (-0,05)**, **Long Beach (0,00)** o **Yas Marina (0,00)** registran promedios nulos de remontada. Esto demuestra que en dichos circuitos la clasificación del sábado determina en casi un 100% el resultado final, obligando a los equipos a buscar adelantamientos mediante estrategia de boxes.

Para consultar el código fuente completo, la trazabilidad técnica y la ejecución detallada de estos 6 estudios analíticos, remitirse al notebook adjunto en el proyecto : **2-AnalisisEDA.ipynb**.

6. MODELADO EN POWER BI

Con el objetivo de transformar los hallazgos analíticos obtenidos en Python en un entorno interactivo y dinámico, se migró el dataset procesado (**f1_data.csv**) a Power BI Desktop.

6.1 Carga y limpieza previa en Power Query

Antes de construir las relaciones del modelo, se ejecutó un proceso de limpieza y examinación previo de los datos al exportarlos del .csv directo con el editor de Power Query:

- **Verificación de Tipos de Datos:** Se validó la correcta asignación de tipos de datos en la tabla principal, asegurando que las métricas cuantitativas (**lap_seconds**, **pit_seconds**, **positions_gained**) se interpretaran como decimales continuos y las claves de cada una de las tablas brutas como números enteros.
- **Categorización Geográfica para Mapeo:** Se categorizó explícitamente el campo **country** como tipo "País o región" (*Country/Region*) dentro de Power BI. Esto fue fundamental para asegurar que la funcionalidad de geolocalización interpretara correctamente todos los países evitando errores y permitiera alimentar de forma precisa el mapa interactivo que se puede ver en el Dashboard 1 (página 1)
- **Tratamiento de Nulos y Nombres:** Se estandarizaron los encabezados y se descartaron ambigüedades en campos de texto para mantener la coherencia en los filtros cruzados.

6.2 Arquitectura del Modelo Relacional


Para maximizar la compresión de datos y evitar redundancias informativas, se desacopló la tabla inicial en pequeñas tablas de información interesantes:

- **Tabla de Hechos (**datosPowerBI**):** Representa el núcleo principal del estudio. Contiene las claves foráneas de relación (**racelId**, **driverId**, **constructorId**, **circuitId**) y las variables métricas continuas (**lap_seconds**, **pit_seconds**, **positions_gained**, **positionOrder**, **points**).
- **Tablas de Dimensiones (**Circuito**, **Conductor**, **Piloto**, **Constructor** y **Carrera**) :** Almacenan los atributos de cada una de las categorías e información útil para el estudio como lo son: nombres completos de pilotos, escuderías, ubicación geográfica de trazados, fechas y temporadas.
- **Relaciones y Filtros:** Se establecieron relaciones relacionales de **1 a Muchos (1:N)** con dirección unidireccional (desde las dimensiones hacia la tabla de hechos), garantizando la integridad referencial.

6.3 Cálculo de Medidas

Se creó una tabla dedicada de medidas (**Medidas**) para guardar las diferentes medidas generales del proyecto mediante fórmulas en lenguaje DAX que serán usadas para los principales KPIs del Dashboard.

- **Total de Grandes Premios (Total Carreras):**
DISTINCTCOUNT(datosPowerBI[raceId]) — Conteo de las carreras evaluadas.
- **Ritmo Promedio (Tiempo Medio Vuelta (s)):**
AVERAGE(datosPowerBI[lap_seconds]) — Cálculo del tiempo medio por vuelta en milésimas de segundos.
- **Promedio de Remontada (Promedio Remontada):** Cálculo del promedio de posiciones ganadas por carrera → **positions_gained**.



6.4 Estructura del Dashboard


El resultado final resultante son **dos dashboards operacionales**, estructurados en dos páginas diferenciadas y complementarias. Esta organización permite adaptar la visualización de la información a las distintas necesidades de análisis, atendiendo tanto a una **perspectiva directiva y global**, orientada al seguimiento del rendimiento y la toma de decisiones, como a una **perspectiva técnica y telemétrica**, centrada en el análisis detallado de los datos obtenidos durante el las carreras y momentos en el que vehículo se encuentra en pista, midiendo as su rendimiento.

Página 1: Dashboard : Rendimiento histórico (1982-2012)

- **Indicadores KPI:** Tarjetas superiores con formato corporativo (rojo F1 y modo oscuro) mostrando el **Total de Carreras**, **Tiempo Promedio de Vuelta** y el **Promedio de Remontada**. Como se ha explicado en el apartado anterior.

NOTA: "Del total de Grandes Premios disputados en el periodo histórico 1982-2012, el dataset contempla 107 carreras que disponen de registros telemétricos homogéneos y completos a nivel de vuelta (278.678 observaciones), por lo que nos quedaremos con esta para el estudio, si no sería un incongruencia usar el número de carreras totales y realizar estandarizaciones o asunciones del resto."

- **Distribución por Escuderías:** Gráfico de barras horizontales mostrando el volumen de victorias por constructor (liderado por McLaren y Williams en el periodo analizado).
- **Geolocalización:** Mapa de burbujas interactivo mediante coordenadas geográficas que distribuye los Grandes Premios por países.
- **Filtrado Temporal:** Segmentador con barra deslizante por rango de años.




Visión general del primer Dashboard

Gracias a las relaciones establecidas entre las diferentes tablas que hemos creado previamente, se consigue una **conexión dinámica entre las tablas, los KPIs y los distintos gráficos** incluidos en el dashboard. Esto permite realizar diferentes consultas y estudios de manera rápida e intuitiva, ya que cualquier modificación realizada mediante los filtros se refleja automáticamente en el resto de elementos visuales.

De esta forma, el usuario puede analizar la evolución de los principales indicadores y obtener conclusiones de manera rápida y visual, sin necesidad de realizar manualmente los cálculos o consultar de forma independiente cada conjunto de datos. Además, la posibilidad de aplicar filtros sobre diferentes variables facilita la comparación entre periodos, escuderías, pilotos y carreras, permitiendo profundizar en aquellos aspectos que resulten de mayor interés.

Por ejemplo, mediante el filtro temporal es posible analizar cómo ha evolucionado el **número de carreras ganadas por cada escudería y piloto**, así como estudiar las diferentes carreras disputadas a lo largo de las temporadas y observar los cambios producidos con el paso de los años.


- **Ejemplo 1:** En este caso, se puede observar cómo se modifican automáticamente los gráficos y los KPIs del dashboard al aplicar un filtro temporal y limitar el periodo de estudio a los años **1982-1990**, en lugar de considerar todo el rango de años disponible. Esto permite centrar el análisis en un periodo concreto y estudiar de forma más detallada el comportamiento de las diferentes escuderías y pilotos durante esos años.



Resultado del ejemplo 1

- **Ejemplo 2:** Al seleccionar una única escudería dentro del primer gráfico, el dashboard adapta automáticamente la información mostrada al equipo seleccionado. De esta forma, los diferentes elementos visuales se actualizan para mostrar exclusivamente los datos relacionados con dicha escudería, permitiendo identificar los pilotos que han formado parte de ella, así como analizar su participación y evolución a lo largo del periodo estudiado.

Del mismo modo, los **KPIs se recalculan y actualizan automáticamente**, proporcionando una visión específica de la escudería seleccionada. Esto permite pasar de una perspectiva general, en la que se analiza el conjunto de equipos, a una perspectiva más particular y detallada, facilitando el estudio individual de cada escudería y la obtención de conclusiones de una manera rápida y visual.




Resultado del ejemplo 2

Página 2: Dashboard Técnico: Telemetría y comparativa de ritmo

La segunda página del dashboard está orientada a un **análisis técnico y detallado del comportamiento de los pilotos y monoplazas durante las carreras**, utilizando para ello la información procedente de los datos de telemetría. El objetivo principal es facilitar la comparación del ritmo en pista y permitir identificar patrones relacionados con la evolución del rendimiento a lo largo de un Gran Premio.

- **Gráfico telemétrico de líneas:** Se representa la evolución del **tiempo por vuelta (lap_seconds)** en función del **número de vuelta (lap)**. Este gráfico permite analizar de manera visual cómo varía el ritmo de un piloto durante el desarrollo de la carrera. Además, ofrece la posibilidad de seleccionar una temporada, un circuito concreto y diferentes pilotos para establecer comparaciones directas entre ellos, por ejemplo, entre Vettel y Hamilton. De esta manera, se pueden identificar diferencias de ritmo, cambios en el rendimiento a medida que avanza la carrera, posibles efectos de la **degradación de los neumáticos** y las variaciones asociadas a las estrategias de carrera. Asimismo, permite detectar de forma visual las vueltas en las que se producen entradas o salidas de boxes y analizar su posible impacto sobre los tiempos registrados.
- **Segmentación avanzada:** Para facilitar un análisis más preciso y adaptado a las necesidades del usuario, el dashboard incorpora diferentes **filtros dinámicos** que permiten segmentar la información según el trazado (**circuit_name**), la temporada (**year**) y el piloto (**driver_full_name**).



7. CONCLUSIÓN

En definitiva, este proyecto ha permitido poner en práctica los conocimientos adquiridos a lo largo del curso, desde el tratamiento y análisis de los datos hasta su organización y representación mediante herramientas de visualización. Más allá de los resultados obtenidos, el desarrollo del dashboard ha permitido comprobar la utilidad de transformar un conjunto de datos amplio y complejo en información que pueda interpretarse de una forma sencilla y rápida. La posibilidad de interactuar con los datos, aplicar diferentes filtros y comparar pilotos, escuderías, circuitos y temporadas facilita la identificación de patrones y la obtención de conclusiones que, de otra manera, serían más difíciles de observar.

Por tanto, el resultado final no se limita únicamente a la creación de un dashboard, sino que supone una forma de **dar valor a los datos mediante su análisis y visualización**, haciendo que la información sea más accesible y útil para la toma de decisiones.